Laboratório 05
O pipeline que pode rodar de novo

Grupo 09 | Execução em 04/11/2026

Integrantes: Renato Santana (representante), João Augusto Pimentel, Raphael Barros e Lara Pessoa.

Resultado verificado na AWS

O pipeline foi provisionado em **us-east-1** com Terraform e backend remoto S3. O verificador original confirmou **70/70 pontos-percentuais automáticos**, e a checagem após a remoção dos recursos confirmou **PASSA [5] (10%)**. As decisões documentadas correspondem aos 20% de avaliação manual; esta evidência não antecipa a nota do professor.

Métrica	Resultado medido
Recursos criados / removidos	10 / 10
Raw: arquivos / dias de chegada	32 / 30
Linhas lidas da raw	535.680
Corridas atrasadas / atraso	1.591 / 3 dias
Duplicatas removidas	17.280
Trusted: linhas / corridas distintas	518.400 / 518.400
Madrugada de 7 dias, antes / depois	11.137 / 11.137
Linhas, antes / depois da reexecução	518.400 / 518.400
Backfill: partições / linhas gravadas	1 / 17.280
Registros fora da janela	0

Arquitetura e implementação

JSON no S3, particionado pelo dia de chegada → Glue/PySpark → Parquet particionado pelo dia do evento → catálogo Glue e Athena com partition projection. Os argumentos do job foram ligados às variáveis: --MODO = sobrescrever; --CHAVE = corrida_id; --JANELA = tostring(3). O script do professor foi preservado.

Estado remoto e lock preexistentes foram preservados. Nenhuma credencial, backend.hcl, arquivo de estado, plano binário ou pasta .terraform integra a entrega.

Quatro decisões justificadas

DECISÃO 01 - modo de escrita

Escolhemos `sobrescrever`, aceitando reconstruir as partições de evento afetadas em vez de acumular arquivos: o verificador executou novamente o mesmo job e mediu **518.400** → **518.400 linhas** e **11.137** → **11.137 corridas de madrugada**, comprovando idempotência.

DECISÃO 02 - chave da linha

Escolhemos `corrida_id`, mantendo a primeira chegada e descartando reenvios da mesma corrida: foram removidas **17.280 duplicatas**, restando **518.400 linhas e 518.400 corridas distintas**; aceitamos não tratar um reenvio com o mesmo identificador como nova corrida.

DECISÃO 03 - janela de atraso

Escolhemos **3 dias**, a menor janela que inclui as **1.591 corridas** atrasadas de 01/11/2026 e mantém **11.137 corridas** de madrugada entre 29/10 e 04/11/2026, com **0 registros fora da janela** nesta carga; aceitamos excluir atrasos maiores da carga diária e recuperá-los por backfill. O script fornecido lê a raw inteira: nesta execução, **30 dias de chegada, 32 arquivos e 535.680 linhas**; a janela filtra o atraso das linhas e não reduz a leitura física para quatro pastas.

DECISÃO 04 - backfill

Para corrigir um dia de evento, inclusive com chegadas além da janela, usamos `./rodar-job.sh DIAS=2026-11-01` (substituindo a data pelo dia afetado): o teste reescreveu **1 partição**, gravou **17.280 linhas** e manteve **518.400 linhas / 518.400 corridas distintas / 11.137 corridas de madrugada** na tabela; aceitamos o custo de reler a raw para reconstruir esse dia, sem duplicar, porque `--DIAS` dispensa o limite superior de atraso, `corrida_id` deduplica e a sobrescrita dinâmica troca somente a partição selecionada.

Limite do teste de backfill

O dia 01/11 já estava completo antes do backfill. O teste comprova a reescrita de uma partição sem alterar os totais; a aceitação de atrasos superiores à janela decorre da lógica do ramo --DIAS no script fornecido. Não foi inventada uma chegada adicional para essa evidência.

Evidências de aceite

Saída do verificador original

OK [0] (elimina) backend remoto s3 e trusted em Parquet

PASSA [1] (20%) a madrugada de 7 dias tem 11137 corridas, incluindo as atrasadas

rodando o job mais uma vez (~3 min) para o critério 2…

PASSA [2] (25%) rodar de novo não mudou nada: 518400 linhas e 11137 na madrugada, antes e depois

PASSA [3] (15%) uma linha por corrida: 518400 linhas, 518400 corridas distintas

PASSA [4] (10%) terraform plan limpo: o segundo apply não mudaria nada

Critérios automáticos: 70 / 70 pontos-percentuais

Falta o que o script não mede: o critério 5 (rode com --pos-destroy depois do destroy) e o DECISOES.md (20%).

evidência: sufixo=grupo09 hoje=2026-11-04 madrugada_7d=11137->11137 linhas=518400->518400 distintas=518400
{"chave_dedup":"corrida_id","janela_atraso_dias":3,"modo_escrita":"sobrescrever"}

Após a remoção dos recursos

PASSA [5] (10%) destroy limpo: nenhum recurso eda-a25-grupo09 sobrou

Rastreabilidade

Os arquivos completos estão em evidencias/: carga, execução inicial, verificador, backfill, relatórios JSON do Glue, consultas Athena, plan limpo, destroy e checagem adicional de ausência de recursos.

Consulta inicial: 53616883-1d42-4a92-a746-7b88564f472c
Consulta após backfill: b828a1a8-e874-4237-8274-6951b2abc84b

Consulta de conferência

```
SELECT count(*) FROM corridas
WHERE dt >= '2026-10-29'
AND faixa_hora BETWEEN 0 AND 5;
```

Fontes e entrega

Enunciado, rubrica, scripts e projeto-base disponibilizados pelo professor Carlos Diego Cavalcanti Pereira na atividade Laboratório 05. Identificação dos integrantes conferida na planilha oficial, grupo 09, linhas 88 a 93.

Atividade no Google Classroom